UACM
Universidad Autónoma de la Ciudad de México
NADA HUMANO ME ES AJENO

Colegio de Ciencia y Tecnología

Plantel San Lorenzo Tezonco

Inteligencia de negocios (BI)

Semestre 2026-II

Optimización del desempeño comercial en la industria de videojuegos: un análisis histórico de ventas para la toma de decisiones estratégicas.

Profesor: Aracelí Liliana Reyes Cabello

Equipo: Risk Analyst

Alumno: Hernández Martínez Ricardo

Repositorio:
https://github.com/Richi0001/proyecto_Bi_Videojuegos

Actualización del avance 1

Pregunta de negocio actualizada:
¿Qué combinaciones de género, plataforma y región han concentrado mayores ventas históricas entre 1980 y 2016, y qué patrones de distribución pueden servir de referencia para la toma de decisiones de inversión en nuevos proyectos de videojuegos?

Persona que usa la información:
El director de estrategia de producto o gerente de portafolio de una desarrolladora o publisher de videojuegos.

Decisión que se busca apoyar:
Informar la toma de decisiones estratégicas sobre género, plataforma y región para nuevos proyectos, con base en patrones históricos de desempeño comercial (entendido como el comportamiento histórico de las ventas en copias y la posición de los videojuegos en el mercado, dado que el dataset no incluye ingresos ni costos).

Cobertura declarada por la fuente: 1980-2020
Cobertura efectiva verificada: 1980-2016
Datos atípicos: los años 2017 (3 registros) y 2020 (1 registro) se identifican como datos atípicos y no se consideran representativos de la industria en esos años. Los años 2018 y 2019 no presentan registros.

Estos casos se conservan en el dataset y se reportan como evidencia en este documento de cobertura real; no se eliminan ni se ocultan, cualquier afirmación sobre tendencias se delimita al periodo 1980-2016.

CONTRATO DE LECTURA

Durante el Avance 1 evaluamos la fuente videoGameSalesWithRatings.csv (Kaggle, Rush4Ratio, licencia pública, 16,719 filas × 16 columnas, cobertura 1980-2017). Se descartó para el análisis principal porque sus altos faltantes en calificaciones (Critic_Score: 8,582; User_Score: 6,704) limitan su utilidad, y no aporta valor necesario para la pregunta de negocio. En el Avance 2 trabajaremos únicamente con vgsales.csv.

Fuente	vgsales.csv
Autor	Gregorut (basado en VGChartz)
Licencia	Pública
Formato	.csv
Ubicación local	/content/vgsales.csv (Colab) /data/raw/vgsales.csv (repo)
Fecha de obtención	Agosto-Septiembre 2026
Estructura esperada	Tabla: una fila por videojuego, 11 columnas

Unidad de observación	Un videojuego con ventas superiores a 100,000 copias
Comprobaciones	type, shape, columns, head
Avisos	Faltantes en Year (271) y Publisher (58)

Cobertura inicial declarada por la fuente principal: 1980-2020.
Cobertura efectiva verificada con el avance 2: 1980-2016.
Nota sobre datos atípicos: los años 2017 (3 registros) y 2020 (1 registro) se identifican como datos atípicos y no se consideran representativos de la industria en esos años. Los años 2018 y 2019 no presentan registros. Estos casos se conservan en el dataset y se reportan como evidencia de la cobertura real; no se eliminan ni se ocultan. Cualquier afirmación sobre tendencias se delimita al periodo 1980-2016.

PERFIL INICIAL

Filas: 16,598
Columnas: 11
Duplicados exactos: 0

Columna	Tipo	Faltantes	%	Distintos
Rank	int64	0	0	16,598
Name	object	0	0	11,493
Platform	object	0	0	31
Year	float64	271	1.63	39
Genre	object	0	0	12
Publisher	object	0	0	578
NA_Sales	float64	0	0	409
EU_Sales	float64	0	0	305
JP_Sales	float64	0	0	244
Other_Sales	float64	0	0	157
Global_Sales	float64	0	0	623

Distribución por año (2010-2020):

Año	Juegos	Interpretación
2010	1,259	Normal
2011	1,139	Normal
2012	657	Normal
2013	546	Normal
2014	582	Normal
2015	614	Normal
2016	344	Normal
2017	3	Atípico
2018	0	Sin registros
2019	0	Sin registros
2020	1	Atípico

Año con más juegos: 2009 (1,431 juegos).
Rango temporal: 1980-2020 antes del análisis inicial; 1980-2016 reales después del análisis detallado.

HALLAZGOS

	Columna / registro	Operación que lo detectó	Evidencia	Efecto analítico	Aclaración pendiente
1	Year	isna().sum()	271 faltantes (1.63%)	No se puede ubicar temporalmente el 1.63% de los juegos	¿La ausencia es original o error de captura? No hay regla documentada para imputar
2	Publisher	isna().sum()	58 faltantes (0.35%)	No se puede atribuir editorial al 0.35%	¿La ausencia significa "sin publisher" o "no capturado"?
3	Year	dtypes	float64 en lugar de entero	Años como 2006.0 dificultan filtros exactos	Convertir a Int64 sin imputar
4	name	nunique()	11,493 nombres	Hay juegos con mismo nombre	Verificar si Name+Platform+Year es

			distintos para 16,598 filas	en distintas plataformas	única
5	rank	describe()	min 1, max 16,600, 16,598 valores distintos	3 rangos no consecutivos (16,600 vs 16,598 filas)	Revisar si es error de la fuente o gaps
6	Ventas regionales	describe()	3 rangos no consecutivos (16,600 vs 16,598 filas)	Un 0 puede ser venta nula real o ausencia disfrazada	Revisar si 0 es valor válido o marcador
7	Global_Sales	describe()	Rango coherente con ventas reales	Rango coherente con ventas reales	No requiere corrección
8	Year	value_counts()	La cobertura real termina en 2016; los años posteriores son casos aislados	La cobertura real termina en 2016; los años posteriores son casos aislados	Confirmar si la fuente dejó de actualizarse después de 2016

REGLAS DE PREPARACIÓN

Regla 1 Conversión de tipo de Year:

I. **Problema:** Year está como float64 (ej. 2006.0) porque contiene faltantes, sabemos que un año es un valor entero; por lo que su representación como decimal dificulta aplicación de filtros y lecturas.
II. **Solución:** convertir a Int64 (entero anulable de Pandas), después revisaremos que los valores no nulos sigan siendo los mismos (16,327).

Regla 2 No asignar valores estimados/inventados a Year:

I. **Problema:** 271 valores faltantes, ya que no existe regla documentada que permita reconstruir/obtener el año de lanzamiento
II. **Solución:** conservar los faltantes, pero excluirlos del subconjunto analítico temporal, por lo que el conteo de faltantes se mantiene en 271.

Regla 3 No asignar valores estimados/inventados a Publisher:

I. **Problema:** 58 faltantes, podría ser "sin publisher" o "no capturado".
II. **Solución:** conservar los faltantes, pero excluirlos del subconjunto cuando se analice por publisher, entonces el conteo de faltantes se mantiene en 58.

Regla 4 — Subconjunto analítico para la pregunta de negocio:

I. **Problema:** la pregunta requiere género, plataforma, región y ventas globales, las filas sin Genre, Platform o Global_Sales no pueden participar del análisis.
II. **Solución:** crear "analisis_videojuegos" con filas que tengan esas columnas y checar que el subconjunto no tenga nulos en esas columnas.

Tratamientos NO pertinentes (técnicas de limpieza y transformación de datos que no es necesario aplicar):

I. No hay duplicados exactos, así que no usamos drop_duplicates() de Python

   df.duplicated().sum()

   Si el resultado es 0, no existen filas completamente duplicadas.

II. No hay problemas de texto ni unidades distintas, significa que no se identificaron inconsistencias relevantes en los campos de texto ni diferencias de unidades que dificulten el análisis como:

Consola	Nombre
PlayStation	Nombre de plataforma
Playstation	Diferencia en mayúsculas
PS	Nombre abreviado

III. No hay fechas completas (solo año) ni unidades que requieran conversión, en este punto indica que la variable de tiempo contiene únicamente el año de lanzamiento y no fechas completas (como 15/06/2018 o 2018-06-15). Por eso, no necesitamos transformar fechas completas a otro formato ni convertir unidades de medida para poder hacer comparaciones.

COMPARACIÓN ANTES / DESPUÉS

	Antes (crudo)	Después (trabajo)	Cambio
Filas	16,598	16,598	Sin cambios
Columnas	11	11	Sin cambios
Duplicados exactos	0	0	Sin cambios
Tipo de Year	float64	INt64	Convertido

Faltantes en Year	271	271	Conservados
Faltantes en Publisher	58	58	Conservados
Faltantes en ventas	0	0	Sin cambios

Subconjuntos creados:

Subconjunto	Criterio	Filas	Uso
analisis_videojuegos	Genre, Platform, Global_Sales presentes	16,598	Análisis principal: ventas por género, plataforma y región
analisis_temporal	Year presente	16,327	Análisis por año (excluye 271 sin año)

VALIDACIÓN

	Comprobación	Resultado
1	Origen conservado (datos_crudos.equals(datos_crudos_original))	True
2	Sin duplicados exactos	True
3	Year convertido a entero (Int64)	True
4	Género y plataforma completos	True
5	Subconjunto sin nulos indispensables	True

Todas las comprobaciones pasaron.

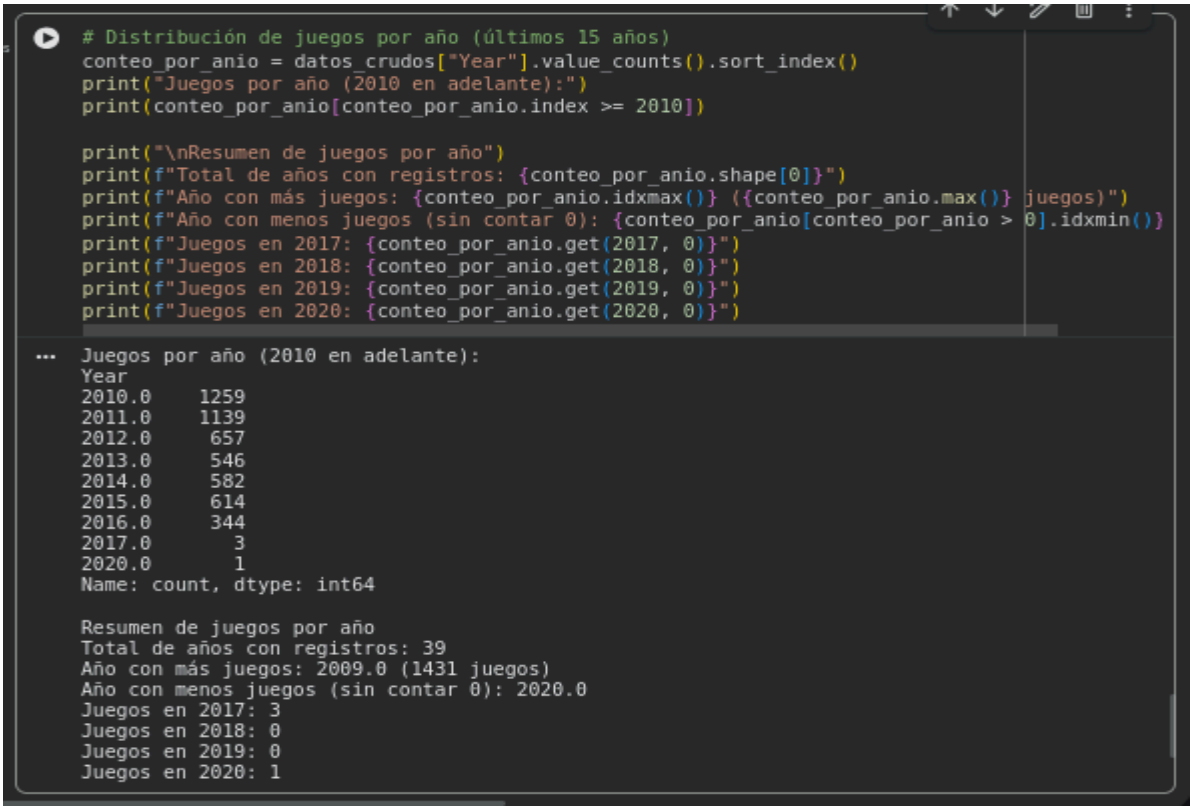
CONCLUSIONES

El dataset cuenta con una cobertura hasta 2020, sin embargo, el análisis detallado con pandas mostró que la concentración real de registros termina en 2016, ya que los años 2017 y 2020 contienen casos atípicos (3 y 1 respectivamente) que no deben interpretarse como tendencia, además los años 2018 y 2019 no tienen registros.

Por lo tanto, cualquier afirmación sobre tendencias o interpretación para el negocio debe limitarse al periodo 1980-2016. Los registros atípicos se conservan en el dataset y se reportan como evidencia de la cobertura real.

La profesora, en el avance 1 indicó que era necesario revisar hasta qué año llegan los datos y documentarlo correctamente, así como ajustar el alcance para no afirmar que el proyecto permite predecir el éxito de un nuevo videojuego ni maximizar ganancias.

Por lo anterior, se ejecutó un conteo de juegos por año:



```
# Distribución de juegos por año (últimos 15 años)
conteo_por_anio = datos_crudos["Year"].value_counts().sort_index()
print("Juegos por año (2010 en adelante):")
print(conteo_por_anio[conteo_por_anio.index >= 2010])

print("\nResumen de juegos por año")
print(f"Total de años con registros: {conteo_por_anio.shape[0]}")
print(f"Año con más juegos: {conteo_por_anio.idxmax()} ({conteo_por_anio.max()} juegos)")
print(f"Año con menos juegos (sin contar 0): {conteo_por_anio[conteo_por_anio > 0].idxmin()}")
print(f"Juegos en 2017: {conteo_por_anio.get(2017, 0)}")
print(f"Juegos en 2018: {conteo_por_anio.get(2018, 0)}")
print(f"Juegos en 2019: {conteo_por_anio.get(2019, 0)}")
print(f"Juegos en 2020: {conteo_por_anio.get(2020, 0)}")
```

```
Juegos por año (2010 en adelante):
Year
2010.0    1259
2011.0    1139
2012.0     657
2013.0     546
2014.0     582
2015.0     614
2016.0     344
2017.0       3
2020.0       1
Name: count, dtype: int64

Resumen de juegos por año
Total de años con registros: 39
Año con más juegos: 2009.0 (1431 juegos)
Año con menos juegos (sin contar 0): 2020.0
Juegos en 2017: 3
Juegos en 2018: 0
Juegos en 2019: 0
Juegos en 2020: 1
```

* Se identificó que la cobertura real termina en 2016, con casos aislados en 2017 (3 registros) y 2020 (1 registro), y sin registros en 2018 y 2019.

Además, se ajustó la pregunta de negocio y el lenguaje del proyecto para cambiar el concepto de “éxito comercial” por otros como “**patrones históricos de desempeño comercial”**, “**rendimiento de ventas”**, “**toma de decisiones estratégicas”**, “**optimización del desempeño comercial”**, “**rentabilidad del negocio”** y “**ROI”**, pero sin afirmaciones sobre el “éxito” o “la predicción” ni “garantizar resultados”.

Datos pueden utilizarse:

I. Las 16,598 filas del dataset para análisis de ventas por género, plataforma y región.
II. Las 16,327 filas con año válido para análisis temporal, delimitadas al periodo 1980-2016 para tendencias.

Conservamos el CSV y datos_crudos sin modificaciones:

I. 271 juegos sin año (1.63%), 58 sin publisher (0.35%)
II. Cobertura real hasta 2016 con casos aislados en 2017 y 2020
III. Ausencia de datos de costos, ingresos y marketing
IV. Datos históricos que no permiten predicción ni cálculo de ROI garantizado

Actualmente, se encuentra este avance como “listo con cautela” para el análisis de patrones históricos de desempeño comercial por género, plataforma y región, para la toma de decisiones estratégicas en nuevos proyectos de videojuegos.