UACM
Universidad Autónoma de la Ciudad de México
NADA HUMANO ME ES AJENO

Colegio de Ciencia y Tecnología

Plantel San Lorenzo Tezonco

Inteligencia de negocios (BI)

Semestre 2026-II

Optimización del desempeño comercial en la industria de videojuegos: un análisis histórico de ventas para la toma de decisiones estratégicas.

Profesor: Araceli Liliana Reyes Cabello

Equipo: Risk Analyst

Alumno: Hernández Martínez Ricardo

Repositorio:
https://github.com/Richi0001/proyecto_Bi_Videojuegos

1. CONTINUIDAD (SEGÚN AVANCES ANTERIORES)

Pregunta de negocio actual:
¿Qué combinaciones de género, plataforma y región han concentrado mayores ventas históricas entre 1980 y 2016, y qué patrones de distribución pueden servir de referencia para la toma de decisiones de inversión en nuevos proyectos de videojuegos?

Queremos apoyar e informar la toma de decisiones estratégicas sobre género, plataforma y región para nuevos proyectos, con base en patrones históricos de desempeño comercial.

Fuente principal: vgsales.csv (Kaggle, Gregorut, pública, 16,598 filas × 11 columnas).

Variables necesarias: Genre, Platform, Year, Global_Sales, NA_Sales, EU_Sales, JP_Sales, Other_Sales.

Ajustes hechos según la retroalimentación de la profesora:

I. Cobertura revisada: Entre 1980-2016 (algunos atípicos en 2017 y 2020 y sin registros en 2018-2019).
II. Concepto ajustado: Antes: "éxito comercial" , después: "desempeño comercial"
III. Pregunta reformulada hacia patrones históricos, no hacia la predicción.

2. CONTRATO DEL ETL

Fuente	vgsales.csv, 16,598 filas × 11 columnas
Unidad de observación	Un videojuego
Clave de negocio	Rank (identificador único por fila)
Integración	1 sola fuente; no cruzamos tablas/fuentes
Entrada esperada	**11 columnas**: Rank, Name, Platform, Year, Genre, Publisher, NA_Sales, EU_Sales, JP_Sales, Other_Sales, Global_Sales
Salida esperada	**12 columnas** (11 originales + decada) con tipos correctos
Cobertura real	1980-2016
Reproducibilidad	Funciones encadenadas: extraer→normalizar→revisar→ preparar→guardar

El proyecto trabaja con una sola fuente: vgsales.csv. No se cruzan tablas ni se integran lotes porque no hay fuentes adicionales necesarias para responder la pregunta de negocio.

Según lo solicitado, si el proyecto utiliza una sola fuente, no es obligatorio inventar un cruce, por lo que no forzamos o inventamos operaciones de merge o concat.

La fuente es una tabla completa (una fila por videojuego), la única transformación de integración es la consolidación interna del archivo en un DataFrame, más la columna decada sacada a partir de Year.

La cardinalidad es 1 fila x videojuego (16,598 registros), sin duplicación por cruce.

Alternativa desechada: la fuente videoGameSalesWithRatings.csv se evaluó en el Avance 1 como alternativa, pero se descartó debido a que cuenta con muchos faltantes en calificaciones (Critic_Score: 8,582; User_Score: 6,704) y porque no aporta variables necesarias para la pregunta de negocio, no lo usaremos tampoco en este avance.

3. REGLAS DE TRANSFORMACIÓN Y VALIDACIÓN

Regla	Fundamento	Operación	Verificación
Deduplicación	Evitar filas idénticas	drop_duplicates()	0 duplicados retirados (el dataset ya estaba limpio)
Year a entero	Un año es un entero; float64 dificulta filtros	astype("Int64")	16,327 no nulos conservados; 271 nulos conservados
Texto con strip	Eliminar espacios accidentales	.str.strip() en Name, Platform, Genre, Publisher	Sin cambios en valores (el dataset ya estaba limpio)
Columna resultante: decada	Agrupar por periodo histórico	(Year // 10) * 10	1980: 205; 1990: 1,769; 2000: 9,208; 2010: 5,144; 2020: 1; NA: 271

3.1. Reglas de validación

3.1.1 Reglas bloqueantes (si falla, la fila pasa a pendientes):

Regla	Condición	Filas que SÍ cumplen
rank_valido	Rank > 0	16,598
name_presente	Name no vacío	16,598
platform_presente	Platform no vacío	16,598
genre_presente	Genre no vacío	16,598
global_sales_valido	Global_Sales ≥ 0	16,598

3.1.2 Reglas reportables (se documentan, pero no excluye nada):

Regla	Condición	Filas que cumplen
year_presente	Year no nulo	16,327 (271 sin año)
publisher_presente	Publisher no nulo	16,540 (58 sin publisher)

El dataset está limpio (en sus columnas principales), en el caso de las ausencias en Year (271) y Publisher (58) son conocidas por nosotros y no impiden el análisis por género, plataforma o ventas. Se reportan pero como limitación, pero no como motivo de exclusión.

4. CONCILIACIÓN DE CONTEOS

Toda fila recibida queda explicada una sola vez:

$$N_{crudos} = N_{repetidas} + N_{válidos} + N_{pendientes}$$

Sustituimos:

$$0 + 16,598 + 0 = 16,598$$

I. **Crudos recibidos:** 16,598
II. **Repetidas retiradas:** 0
III. **Válidos:** 16,598
IV. **Pendientes:** 0
V. **Listos (salen de los válidos):** 16,598

La tabla listos sale de válidos (solo se agregó la columna decada), no se suma nuevamente.

5. ANÁLISIS ESTADÍSTICO DESCRIPTIVO

5.1. Matriz resumen (por medidas)

	Pregunta	Estadístico	Resultado
1	Ventas por género	Media y mediana	Media máx: 0.94 (Platform)
2	Variabilidad por plataforma	Desviación estándar	Desv. máx: 3.14 (Wii)
3	Frecuencias de género	Frecuencias y porcentajes	Género más frecuente: Action (19.98%)
4	Percentiles de ventas	Percentiles 25, 50, 75, 90, 99	Mediana: 0.17 M
5	Correlación NA-EU	Pearson	r = 0.7677

Elegimos **5 medidas** para la pregunta de negocio, se calcularon sobre listos (16,598 filas).

5.2. Medidas, resultados e interpretación

Pregunta analítica	Variable	Medida	Resultado	Interpretación
¿Cómo se distribuyen las ventas por género?	Genre, Global_Sales	Media y mediana	Platform: media 0.94 Mill, mediana 0.28 Mill; Action: media 0.53 Mill, mediana 0.19 Mill	La **mediana** es menor que la **media** en todos los géneros: distribución sesgada a la derecha, y el género más frecuente (Action) no es el de mayor media
¿Qué plataformas tienen mayor variabilidad?	Platform, Global_Sales	Desviación estándar	Wii: 3.14; X360: 1.62; DS: 1.43; PSP: 0.52	Wii es la más dispersa: conviven juegos muy exitosos (Wii Sports, 82.74 Millones) y fracasos. PSP es la más concentrada
¿Qué géneros concentran más lanzamientos?	Genre	Frecuencias y porcentajes	Action: 3,316 (19.98%); Sports: 2,346 (14.13%); Puzzle: 582 (3.51%)	Los géneros más frecuentes tienen más competencia, pero no necesariamente mayor rentabilidad
¿Cómo se distribuyen las ventas globales?	Global_Sales	Percentiles 25, 50, 75, 90, 99	0.06, 0.17, 0.47, 1.21, 5.43 M	El 50% de los juegos vende menos de 0.17 Mill. Solo el 1% supera 5.43 Mill, es una distribución muy concentrada.
¿Existe asociación entre ventas de NA y EU?	NA_Sales, EU_Sales	Correlación de Pearson	r = 0.7677	Correlación lineal positiva fuerte, los mercados occidentales tienden a moverse juntos, pero no demuestra causalidad con ello

5.3. Hallazgos principales para la decisión de negocio

1. **El género más frecuente no es el más rentable en promedio.** Action concentra el 19.98% de los lanzamientos, pero su media (0.53 Millones) está por debajo de Platform (0.94 Millones) y Shooter (0.79 Millones).
2. **La distribución de ventas está muy concentrada.** El 50% de los juegos vende menos de 0.17 Millones; solo el 1% supera 5.43 Millones. El éxito masivo es la excepción, no la regla.
3. **Las plataformas difieren en variabilidad.** Wii tiene la desviación std más alta (3.14): significaría mayor potencial de éxito, pero también mayor riesgo. PSP es la más homogénea (0.52).
4. **Los mercados occidentales se mueven juntos.** r = 0.7677 entre NA_Sales y EU_Sales. Una estrategia para Occidente puede tener alcance regional amplio, no solo en un país.

Estos patrones históricos pueden servir para interpretar junto con la pregunta de negocio, como referencia para la planeación comercial. No predicen el éxito de un nuevo juego, pero muestran qué combinaciones han concentrado más ventas en el pasado.

6. BITÁCORA

La función anotar() se adaptó de la Nota 11 con los campos requeridos: fecha, archivo, paso, filas_antes, filas_despues, regla, resultado, observaciones, responsable.

Pasos registrados (9):

Paso	Antes	Después	Resultado
leer	16,598	16,598	Correcto
retirar_repetidas	16,598	16,598	Correcto
normalizar	16,598	16,598	Correcto
revisar	16,598	16,598	Con observaciones
separar	16,598	16,598	Correcto
preparar	16,598	16,598	Correcto
analisis_estadistico	16,598	16,598	Correcto
conciliar	16,598	16,598	Correcto
guardar	16,598	16,598	Correcto

El archivo bitacora.csv se genera automáticamente en la carpeta de salida.

7. SALIDAS GENERADAS

Archivo	Contenido	Filas	Tamaño
listos.csv	Datos preparados (12 columnas)	16,598	1.49 MB
pendientes.csv	Registros que no cumplen reglas bloqueantes	0	92 bytes
controles.csv	Resultados de las 7 reglas por fila	16,598	581 KB
bitacora.csv	Registro automático de las 9 operaciones	9	N/A

Verificación de reproducibilidad: el proceso se ejecutó dos veces usando la fuente original. Las dos ejecuciones produjeron a listos idénticos (mismas filas, columnas y valores). Solo cambian la fecha de la bitácora y el nombre de la carpeta.

Verificación del contrato de salida: columnas (12), tipos (Int64 para Year y decada, float64 para ventas), rangos (Global_Sales >= 0, Rank > 0), categorías (Genre y Platform no vacíos) y clave única (Rank), todas las comprobaciones pasaron.

8. LIMITACIONES

1. **Cobertura parcial:** el dataset declara una cobertura de 1980-2020, pero la concentración real de registros termina en 2016. Los años 2017 (3 registros) y 2020 (1 registro) son atípicos; 2018-2019 no tienen registros, por lo que cualquier análisis por año debe limitarse al periodo de 1980 a 2016.
2. **Faltantes conservados:** 271 registros sin Year (1.63%) y 58 sin Publisher (0.35%). No se modificaron ya que no hay regla para ello. Se guardan en listos y se reportan como limitación, para análisis por año o por publisher, esas filas quedan fuera.
3. **Sin datos de costos ni ingresos:** la fuente solo contiene ventas en copias (millones). No permite calcular ROI, rentabilidad ni ingresos. Las medidas estadísticas describen ventas, no ganancias.
4. **Datos históricos:** el análisis describe patrones del pasado. No predice el éxito futuro de un nuevo videojuego. La pregunta de negocio se ajustó en el Avance 1 para reflejar esta limitación.
5. **Una sola fuente:** no se integraron fuentes adicionales porque no eran necesarias. Esto limita el análisis a las variables disponibles en vgsales.csv.
6. **Correlación no es causalidad:** la medida 5 (Pearson = 0.7677 entre NA_Sales y EU_Sales) describe una asociación histórica, no una relación causa-efecto.

9. CONCLUSIONES

El ETL reproducible se ejecutó de principio a fin sobre vgsales.csv, conservó la fuente original sin modificaciones y generó cuatro salidas verificables: listos.csv (16,598 filas × 12 columnas), pendientes.csv (vacío), controles.csv (16,598 filas × 7 reglas) y bitacora.csv (9 pasos).

Conciliación: 16,598 = 0 + 16,598 + 0.

Todas las filas recibidas quedan explicadas una sola vez.

Análisis estadístico: las 5 medidas muestran que (a) el género más frecuente no es el de mayor media, (b) la distribución de ventas está muy concentrada (mediana 0.17 M, p99 5.43 M), (c) las plataformas difieren en variabilidad (Wii 3.14 vs PSP 0.52), y (d) los mercados de NA y EU están fuertemente asociados (r = 0.7677).

Para la decisión de negocio: estos patrones históricos pueden servir de referencia para la planeación comercial de nuevos proyectos. No predicen el éxito, pero muestran qué combinaciones han concentrado más ventas entre 1980 y 2016.

Estado: listo con cautela. El proceso es reproducible y verificable, pero las limitaciones de cobertura, faltantes y ausencia de datos de costos deben considerarse al interpretar los resultados.