Avance 2: Lectura, perfilamiento y preparación de datos con Python

Optimización del desempeño comercial en la industria de videojuegos

---

Equipo: Risk Analysts

Alumno: Hernández Martínez Ricardo

Semestre: 2026-2

Fecha: 16 de octubre de 2026

Repositorio: `https://github.com/Richi0001/proyecto_Bi_Videojuegos`

Continuidad con el Avance 1

Foco del Proyecto

Pregunta de Negocio:

> *"¿Qué combinaciones de género, plataforma y región han concentrado mayores ventas históricas y qué patrones sirven para invertir en nuevos proyectos?"*

Interesado: Director de estrategia de producto

Decisión: Inversión estratégica basada en desempeño comercial histórico.

Fuente: `vgsales.csv` (Gregorut, Kaggle)

Ajustes por Retroalimentación

- **Cobertura Temporal:** Ajustada a 1980-2016 tras verificación técnica del dataset.
- **Lenguaje Técnico:** Uso de "desempeño comercial" para mayor precisión analítica.
- **Enfoque Metodológico:** Reformulación hacia patrones históricos, evitando promesas de predicción incierta.

Estos ajustes garantizan la alineación entre la promesa de negocio y la capacidad real de los datos.

Lectura Reproducible

Contrato de Lectura

Dataset:	Video Game Sales (Kaggle)
Autor:	Gregorut (VGChartz)
Licencia:	Pública
Archivo:	vgsales.csv
Formato:	CSV
Estructura:	16,598 filas × 11 columnas
Cobertura declarada:	1980 - 2020
Cobertura efectiva:	1980 - 2016

⚠Detección de 271 faltantes en 'Year' y 58 en 'Publisher' durante la carga inicial.

Protocolo de Verificación (Python)

```
df = pd.read_csv('vgsales.csv') print(df.shape) # 16598, 11
print(df.dtypes) print(df.isna().sum()) print(df.head())
```

Comprobaciones de Integridad

- Tipo de datos consistente ✓
- Dimensiones esperadas ✓
- Nombres de columnas claros ✓
- Carga sin errores de encoding ✓

Perfil Inicial y Calidad de Datos

Resumen de Calidad por Columna

Columna	Tipo de Dato	Faltantes	% Calidad
Rank / Name	int64 / object	0	100.00%
Platform / Genre	object / object	0	100.00%
Publisher	object	58	99.65%
Year	float64 (raw)	271	98.37%
Ventas (Global/Reg)	float64	0	100.00%

Distribución Temporal Atípica (2016-2020)

2016: Volumen base final	344 juegos
2017: Ruido estadístico	3 juegos
2018 - 2019: Vacío de datos	0 juegos
2020: Registro único aislado	1 juego

Dimensiones Clave

16,598
FILAS TOTALES

11
COLUMNAS

31
PLATAFORMAS

12
GÉNEROS

Hallazgos de Integridad

Duplicados exactos: 0
Publishers únicos: 578
Rango efectivo: 1980 - 2016

Nota: La brecha 2017-2020 confirma que el análisis debe limitarse hasta 2016 para ser estadísticamente representativo.

Preparación y Validación de Datos

Reglas de Transformación

Conversión de Tipos:
`Year: float64 → Int64` . Estandarización para visualización temporal.

Política de Nulos:
No se imputa 'Year' ni 'Publisher'. Se conservan los faltantes para evitar sesgos artificiales en el análisis.

Selección Analítica:
Creación del subconjunto `analisis_videojuegos` con las 16,598 filas originales listas para procesar.

Dashboard de Validación

Origen de datos conservado	VERIFICADO
Ausencia de duplicados exactos	VERIFICADO
Consistencia en tipos numéricos	VERIFICADO
Género y Plataforma completos	VERIFICADO
Subconjunto sin nulos críticos	VERIFICADO

Protocolo de validación 100% reproducible en Python.

Límites y Próximos Pasos

Límites del Análisis

- **Faltantes técnicos:** 1.63% de registros sin año y 0.35% sin distribuidor.
- **Sesgo Temporal:** Cobertura representativa solo hasta 2016.
- **Alcance Económico:** Sin datos de costos (CAPEX/OPEX), ingresos netos ni marketing.
- **No Predictivo:** No permite garantizar ROI, solo identificar patrones históricos.

Hoja de Ruta Metodológica

- **ETL Robusto:** Automatización de la carga y limpieza.
- **PostgreSQL:** Persistencia de datos en esquema relacional.
- **SQL Analítico:** Consultas avanzadas para cruce de variables.
- **Visualización:** Reporte ejecutivo interactivo en Power BI.

