BI & Analytics SEMESTRE 2026-2

UACM | C&T

Avance 3: Integración, análisis descriptivo y diseño de un ETL reproducible

Optimización del desempeño comercial en la industria de videojuegos

EQUIPO
Risk Analysts

ALUMNO
Hernández Martínez Ricardo

FECHA
8 de noviembre de 2026

REPOSITORIO
github.com/Richi0001/proyecto_Bi_Videojuegos

SECCIÓN 3.1 — CONTINUIDAD

UACM | C&T

Continuidad: pregunta, decisión y ajustes

PREGUNTA VIGENTE

¿Qué combinaciones de género, plataforma y región han concentrado mayores ventas históricas entre 1980 y 2016, y qué patrones de distribución pueden servir de referencia para la toma de decisiones de inversión en nuevos proyectos de videojuegos?

DECISIÓN A APOYAR

Informar la toma de decisiones estratégicas sobre género, plataforma y región para nuevos proyectos.

AJUSTES POR RETROALIMENTACIÓN

- **Cobertura real verificada:** 1980–2016 (atípicos en 2017 y 2020, sin registros en 2018–2019).
- **Lenguaje ajustado:** "desempeño comercial" en lugar de "éxito comercial".
- **Pregunta reformulada:** orientada a patrones históricos, no predicción.

FUENTE PRINCIPAL

`vgsales.csv` **(Kaggle, Gregorut, CC0)**

16,598 × 11

SECCIÓN 3.2 — ARQUITECTURA DE DATOS

UACM | C&T

Fuentes e integración: una sola tabla, sin cruces artificiales

ASPECTO	DEFINICIÓN EN EL PROYECTO
Fuente de datos	`vgsales.csv` (Kaggle, Pública)
Dimensiones originales	16,598 filas × 11 columnas
Unidad de observación	Un videojuego individual
Clave de negocio	`Rank` (identificador único)
Cobertura temporal	1980 – 2016 (verificada)
Estrategia de integración	Una sola fuente principal (sin cruces)

Justificación Técnica

La guía establece que si el proyecto usa una fuente completa no es obligatorio inventar cruces. La fuente con ratings se descartó por alto sesgo de nulos (Score Críticos: 8,582; Usuarios: 6,704).

CARDINALIDAD DE LA FUENTE

1 fila por videojuego. Cero riesgo de duplicación por uniones.

ETL: contrato, funciones y secuencia

ETAPA	FUNCIÓN PYTHON	ACCIÓN REALIZADA
Extracción	`extraer()`	Lee archivo CSV original y verifica la presencia exacta de las 11 columnas esperadas.
Normalización	`normalizar()`	Convierte `Year` a Int64; aplica `strip()` a textos para eliminar espacios accidentales.
Validación	`revisar()`	Evalúa 7 reglas de calidad por cada fila generando controles booleanos.
Separación	*(Lógica interna)*	Divide el dataset en registros totalmente válidos vs. pendientes de revisión.
Preparación	`preparar()`	Genera la columna derivada `decada` y ordena la salida por `Rank`.
Guardado	`to_csv()`	Exporta las 3 tablas resultantes (`listos` , `pendientes` , `controles`) y `bitacora.csv` .

CONTRATO DE ENTRADA/SALIDA

Entrada: 11 columnas. **Salida:** 12 columnas (11 originales + `decada`).

PRUEBA DE REPRODUCIBILIDAD

Proceso ejecutado dos veces seguidas. Salida comprobada con `equals()` → **Resultados 100% idénticos**.

Transformaciones: reglas justificadas y resultado

REGLA DE TRANSFORMACIÓN	FUNDAMENTO TÉCNICO	RESULTADO EN EL DATASET
Deduplicación completa	Evitar registros idénticos en la fuente	**0 duplicados** (fuente ya limpia)
`Year` **a Int64**	Un año es entero; float dificulta filtros	**16,327** no nulos; **271** nulos conservados
Texto con `strip()`	Eliminar espacios invisibles en bordes	Cadenas limpias sin alteración
Columna derivada `decada`	Permite agrupaciones por periodo histórico	1980: 205 | 1990: 1,769 | 2000: 9,208 2010: 5,144 | 2020: 1 | NA: 271

Operaciones No Aplicadas

- **Cruces (** `merge` **):** no hay segunda fuente útil.
- **Concatenaciones (** `concat` **):** sin múltiples lotes.
- **Imputaciones:** sin regla justificada para reemplazar `Year` o `Publisher` .

SALIDA PREPARADA FINAL

`listos.csv` **(16,598 filas × 12 columnas)**

SECCIÓN 3.4 — VALIDACIÓN E INTEGRIDAD

Validación y conciliación: 16,598 = 0 + 16,598 + 0

UACM | C&T

REGLA DE VALIDACIÓN	CLASIFICACIÓN	FILAS QUE CUMPLEN
`rank_valido`	Bloqueante	**16,598** (100%)
`name_presente`	Bloqueante	**16,598** (100%)
`platform_presente`	Bloqueante	**16,598** (100%)
`genre_presente`	Bloqueante	**16,598** (100%)
`global_sales_valido`	Bloqueante	**16,598** (100%)
`year_presente`	Reportable	**16,327** (271 sin año)
`publisher_presente`	Reportable	**16,540** (58 sin pub.)

ECUACIÓN DE CONCILIACIÓN

16,598 = 0 + 16,598 + 0

Crudos (16,598) = Repetidos (0) + Válidos (16,598) + Pendientes (0) → **Verdadero**

VERIFICACIÓN DEL CONTRATO

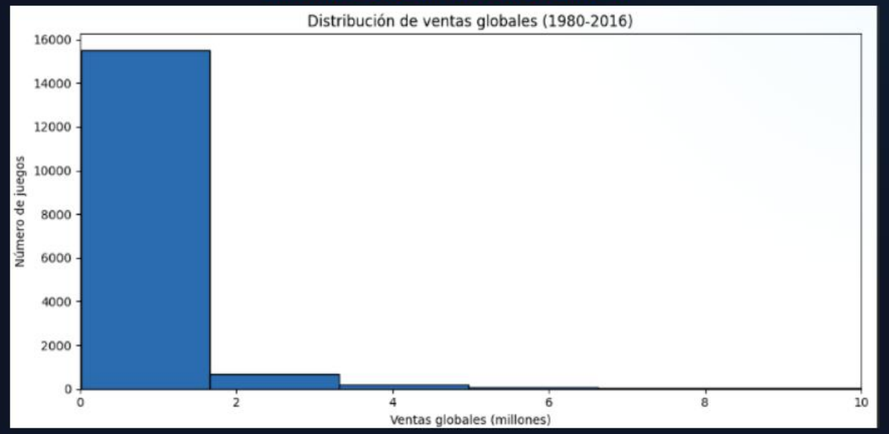
Columnas (12), tipos (`Int64` , `float64`), rangos (`Global_Sales ⩾ 0`) y unicidad de clave (`Rank`) verificados sin excepciones.

5 medidas para la decisión de negocio

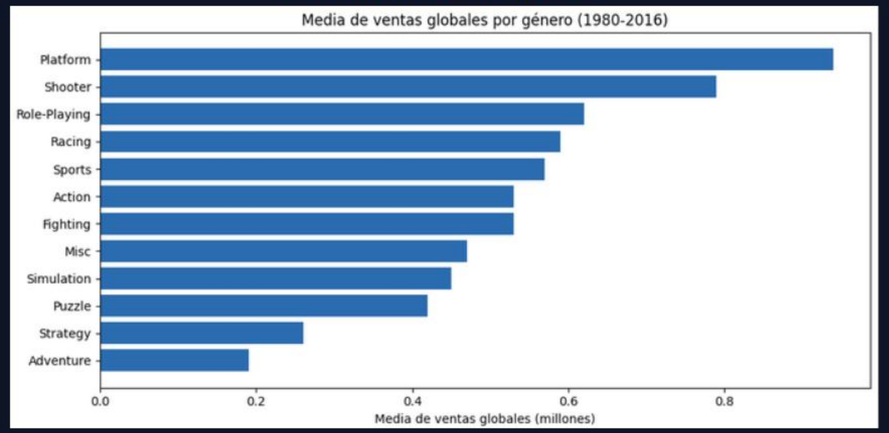
#	MEDIDA	RESULTADO / INTERPRETACIÓN
1	**Media / Mediana**	Platform (0.94M / 0.28M) vs Action (0.53M). Frecuencia ≠ promedio.
2	**Desv. Estándar**	Wii (3.14) vs PSP (0.52). Wii con mayor variabilidad y riesgo.
3	**Frec. Relativa**	Action (19.98%) y Sports (14.13%) concentran la oferta.
4	**Percentiles**	p50: 0.17M | p99: 5.43M. Éxito masivo es una excepción (1%).
5	**Correlación**	Pearson r = 0.7677 (NA vs EU). Coincidencia en mercados.

Hallazgo Clave: El 50% vende menos de 0.17M copias. La inversión debe planificarse considerando que el éxito masivo es la excepción.

DISTRIBUCIÓN DE VENTAS GLOBALES



MEDIA DE VENTAS POR GÉNERO



SECCIÓN 3.6 & 3.7 — TRAZABILIDAD Y CIERRE

Bitácora, limitaciones y cierre

UACM | C&T

Bitácora Automática (9 Pasos)

`leer → retirar_repetidas → normalizar → revisar → separar → preparar → analisis_estadistico → conciliar → guardar`

Campos registrados: `fecha`, `archivo`, `paso`, `filas_antes`, `filas_despues`, `regla`, `resultado`, `observaciones`, `responsable`.

Siguientes Pasos

- Carga de la tabla limpia en **PostgreSQL**.
- Consultas SQL analíticas por género y región.
- Construcción del reporte interactivo en **Power BI**.

Limitaciones del Análisis

- **Cobertura real:** 1980–2016 (registros 2017 y 2020 atípicos).
- **Nulos conservados:** 271 sin `Year` (1.63%) y 58 sin `Publisher` (0.35%) no imputados.
- **Sin costos ni presupuestos:** los datos miden ventas globales en copias, no rendimiento ni ROI financiero.
- **Datos históricos:** patrones del pasado no garantizan éxito futuro.
- **Correlación no implica causalidad.**

Estado: ETL completo, reproducible y validado

Avance 3 — Conclusión

¡Gracias por su atención!

EQUIPO
Risk Analysts

ALUMNO
Hernández Martínez Ricardo

REPOSITORIO GITHUB
Richi0001/proyecto_Bi_Videojuegos